



«Βαθιά Μάθηση»

Ταξινόμηση Ειδών Πτηνών από Βιοακουστικά Σήματα με Τεχνικές Βαθιάς Μάθησης

Ελπίδα Γκούβρα (mtn2504)

Στέλλα Χαντάβα (mtn2528)

Περίληψη

Η αυτόματη αναγνώριση ειδών μέσω ηχητικών καταγραφών αποτελεί ένα ιδιαίτερα σημαντικό πεδίο έρευνας στη βιοακουστική, την παρακολούθηση της βιοποικιλότητας και την προστασία των οικοσυστημάτων. Η ανάπτυξη σύγχρονων τεχνικών βαθιάς μάθησης επιτρέπει την εξαγωγή σύνθετων ακουστικών προτύπων από ηχογραφήσεις φυσικού περιβάλλοντος, διευκολύνοντας την αναγνώριση ειδών χωρίς την ανάγκη χειροκίνητης εξαγωγής χαρακτηριστικών.

Στην παρούσα εργασία μελετάται το πρόβλημα της ταξινόμησης ειδών από ηχητικά δεδομένα χρησιμοποιώντας το σύνολο δεδομένων BirdCLEF 2026[1]. Οι ηχογραφήσεις μετατρέπονται σε αναπαραστάσεις Mel Spectrogram και από κάθε καταγραφή χρησιμοποιούνται τα πρώτα 15 δευτερόλεπτα, τα οποία διαχωρίζονται σε τρία διαδοχικά μη επικαλυπτόμενα χρονικά παράθυρα διάρκειας πέντε δευτερολέπτων. Στη συνέχεια αξιολογούνται δύο αρχιτεκτονικές βαθιάς μάθησης: ένα αμιγώς Συνελικτικό Νευρωνικό Δίκτυο (CNN) και ένα υβριδικό μοντέλο CNN-BiLSTM, το οποίο συνδυάζει την εξαγωγή χωρικών χαρακτηριστικών με τη μοντελοποίηση χρονικών εξαρτήσεων.

Επιπλέον, διερευνώνται διαφορετικές στρατηγικές συνάθροισης (pooling) των χαρακτηριστικών που εξάγονται από τα επιμέρους χρονικά παράθυρα, με στόχο την αποτελεσματικότερη αναπαράσταση κάθε ηχογράφησης. Τέλος, τα προτεινόμενα μοντέλα συγκρίνονται με μία προσέγγιση αναφοράς (baseline) που βασίζεται σε προεκπαιδευμένα βιοακουστικά embeddings του μοντέλου Perch και ταξινομητή Logistic Regression.

1 Εισαγωγή

Η παρακολούθηση της βιοποικιλότητας αποτελεί μία από τις σημαντικότερες προκλήσεις της σύγχρονης οικολογίας και περιβαλλοντικής επιστήμης. Η ακριβής καταγραφή της παρουσίας και της κατανομής των ειδών είναι απαραίτητη τόσο για την προστασία απειλούμενων ειδών όσο και για την κατανόηση των επιπτώσεων της κλιματικής αλλαγής και της ανθρώπινης δραστηριότητας στα φυσικά οικοσυστήματα. Ωστόσο, οι παραδοσιακές μέθοδοι παρακολούθησης βασίζονται συχνά σε χειροκίνητες παρατηρήσεις και εξειδικευμένο προσωπικό, γεγονός που καθιστά τη διαδικασία χρονοβόρα, δαπανηρή και δύσκολα επεκτάσιμη σε μεγάλη κλίμακα.

Τα τελευταία χρόνια, η ραγδαία ανάπτυξη των συστημάτων παθητικής ακουστικής παρακολούθησης (Passive Acoustic Monitoring - PAM) έχει δημιουργήσει τεράστιες συλλογές ηχητικών δεδομένων από φυσικά περιβάλλοντα. Οι καταγραφές αυτές περιέχουν πολύτιμη πληροφορία σχετικά με την παρουσία και τη δραστηριότητα πολλών ειδών, ιδιαίτερα πτηνών, αμφιβίων και εντόμων, τα οποία επικοινωνούν μέσω χαρακτηριστικών φωνητικών σημάτων. Παράλληλα, η πρόοδος στον τομέα της

Τεχνητής Νοημοσύνης και ειδικότερα της Βαθιάς Μάθησης έχει επιτρέψει την ανάπτυξη αυτοματοποιημένων συστημάτων ικανών να αναγνωρίζουν είδη απευθείας από ηχητικές καταγραφές με ολόένα και μεγαλύτερη ακρίβεια.

Στο πλαίσιο αυτό, διαγωνισμοί και ερευνητικές πρωτοβουλίες όπως το BirdCLEF έχουν συμβάλει σημαντικά στην πρόοδο του πεδίου, παρέχοντας μεγάλης κλίμακας σύνολα δεδομένων. Παρά τις σημαντικές επιτυχίες που έχουν σημειωθεί, η αναγνώριση ειδών παραμένει ένα απαιτητικό πρόβλημα. Η παρουσία θορύβου περιβάλλοντος, οι διαφορές στις συνθήκες καταγραφής, η μεγάλη ενδοειδική ποικιλογένεση των φωνών καθώς και οι ομοιότητες μεταξύ συγγενικών ειδών δυσκολεύουν σημαντικά τη διαδικασία ταξινόμησης.

2 Περιγραφή Προβλήματος

Το βασικό πρόβλημα που εξετάζεται στην παρούσα εργασία είναι η αυτόματη αναγνώριση ειδών άγριας ζωής από ηχητικές καταγραφές χρησιμοποιώντας τεχνικές βαθιάς μάθησης. Ως σύνολο δεδομένων χρησιμοποιείται το BirdCLEF 2026 [1].

Από το σύνολο BirdCLEF 2026 επιλέχθηκαν οι 30 συχνότερα εμφανιζόμενες κατηγορίες ειδών. Για κάθε είδος επιλέχθηκαν τυχαία 405 ηχογραφήσεις ώστε να δημιουργηθεί ένα ισορροπημένο σύνολο δεδομένων. Ο αριθμός των δειγμάτων δεν επιλέχθηκε αυθαίρετα, αλλά αντιστοιχεί στο πλήθος των ηχογραφήσεων της κλάσης με τα λιγότερα διαθέσιμα δεδομένα.

Το τελικό σύνολο περιλαμβάνει:

- 12.150 ηχογραφήσεις
- 30 είδη
- 405 ηχογραφήσεις ανά είδος

Χρησιμοποιήθηκε διαχωρισμός του συνόλου δεδομένων σε σύνολα εκπαίδευσης (70%), επικύρωσης (15%) και ελέγχου σε επίπεδο ηχογράφησης (15%). Το τελικό σύνολο περιλάμβανε 8505 δείγματα εκπαίδευσης, 1822 δείγματα επικύρωσης και 1823 δείγματα ελέγχου.


3 Θεωρητικό Υπόβαθρο

3.1 Αναγνώριση Ειδών μέσω Βιοακουστικών Δεδομένων

Η αυτόματη αναγνώριση ειδών μέσω ηχητικών καταγραφών αποτελεί ένα ενεργό πεδίο έρευνας στη βιοακουστική και την υπολογιστική οικολογία. Η ανάπτυξη συστημάτων παθητικής ακουστικής παρακολούθησης επιτρέπει τη συλλογή μεγάλου όγκου δεδομένων από φυσικά περιβάλλοντα, δημιουργώντας την ανάγκη για αυτοματοποιημένες μεθόδους ανάλυσης και ταξινόμησης. Τα τελευταία χρόνια, η εφαρμογή τεχνικών βαθιάς μάθησης έχει οδηγήσει σε σημαντικές βελτιώσεις στην αναγνώριση ειδών από ηχητικά σήματα, ιδιαίτερα μέσω της χρήσης φασματικών αναπαραστάσεων και νευρωνικών δικτύων [1].

3.2 Mel Spectrograms

Οι ηχητικές κυματομορφές αποτελούν χρονοσειρές μεγάλης διάστασης, γεγονός που καθιστά δύσκολη την άμεση επεξεργασία τους. Για τον λόγο αυτό χρησιμοποιούνται συχνά μετασχηματισμοί που μεταφέρουν το σήμα στο πεδίο των συχνοτήτων. Μία από τις πλέον διαδεδομένες προσεγγίσεις είναι τα Mel Spectrograms, τα οποία βασίζονται στον Μετασχηματισμό Fourier Βραχέος Χρόνου (Short-Time Fourier Transform - STFT) και στην κλίμακα Mel, η οποία προσεγγίζει τον τρόπο με τον οποίο αντιλαμβάνεται ο άνθρωπος τις συχνότητες [2].



Σχήμα 1: Παράδειγμα Mel Spectrogram από το dataset.

Η αναπαράσταση αυτή διατηρεί ταυτόχρονα τη χρονική και φασματική πληροφορία, επιτρέποντας τη μετατροπή του ήχου σε εικόνα και κατ' επέκταση την εφαρμογή τεχνικών υπολογιστικής όρασης για την εξαγωγή ακουστικών χαρακτηριστικών.

3.3 Συνελικτικά Νευρωνικά Δίκτυα (CNN)

Τα Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNNs) αποτελούν μία από τις πιο επιτυχημένες κατηγορίες μοντέλων βαθιάς μάθησης για την επεξεργασία δεδομένων με χωρική δομή [3]. Στην περίπτωση των Mel Spectrograms, τα CNN μπορούν να εντοπίσουν τοπικά μοτίβα τα οποία αντιστοιχούν σε χαρακτηριστικές συχνότητες, αρμονικές μεταβολές ή και χρονικές μεταβολές του σήματος.

Μέσω διαδοχικών επιπέδων συνέλιξης (convolutional layers) και υποδειγματοληψίας (pooling), τα δίκτυα δημιουργούν ολοένα και πιο αφηρημένες αναπαραστάσεις των δεδομένων, οι οποίες χρησιμοποιούνται στη συνέχεια για την τελική ταξινόμηση.

3.4 Δίκτυα LSTM και BiLSTM

Παρότι τα CNN είναι ιδιαίτερα αποτελεσματικά στην εξαγωγή τοπικών χαρακτηριστικών, δεν έχουν σχεδιαστεί για τη μοντελοποίηση μακροχρόνιων χρονικών εξαρτήσεων. Για τον σκοπό αυτό χρησιμοποιούνται δίκτυα Long Short-Term Memory (LSTM), τα οποία διαθέτουν ειδικούς μηχανισμούς μνήμης που τους επιτρέπουν να διατηρούν πληροφορία για μεγάλο χρονικό διάστημα [4].

Μία επέκταση των LSTM αποτελούν τα Bidirectional LSTM (BiLSTM), τα οποία επεξεργάζονται τις ακολουθίες τόσο προς τη φυσική όσο και προς την αντίστροφη χρονική κατεύθυνση [5]. Με τον τρόπο αυτό το μοντέλο μπορεί να αξιοποιήσει πληροφορία τόσο από το παρελθόν όσο και από το μέλλον μιας ακολουθίας, οδηγώντας συχνά στη βελτίωση της απόδοσης σε προβλήματα ταξινόμησης ακολουθιών.

4 Προεπεξεργασία Δεδομένων

Κάθε ηχογράφηση μετατράπηκε αρχικά σε *Mel Spectrogram*, ώστε το ηχητικό σήμα να αναπαρασταθεί ταυτόχρονα ως προς τον χρόνο και τη συχνότητα. Η μετατροπή πραγματοποιήθηκε με

συχνότητα δειγματοληψίας (*sampling rate*) 32 kHz, επιτρέποντας την ανάλυση συχνοτήτων έως 16 kHz, σύμφωνα με το θεώρημα δειγματοληψίας Nyquist.

Για την ανάλυση στο πεδίο των συχνοτήτων χρησιμοποιήθηκε Μετασχηματισμός Fourier Βραχέος Χρόνου (*Short-Time Fourier Transform - STFT*) με μέγεθος παραθύρου FFT ίσο με 2048 δείγματα. Με δεδομένη τη συχνότητα δειγματοληψίας των 32.000 Hz, κάθε παράθυρο αντιστοιχεί σε χρονικό διάστημα:

$$t = \frac{2048}{32000} = 0.064 \text{ sec}$$

δηλαδή περίπου 64 ms.

Το *hop length* ορίστηκε σε 512 δείγματα, γεγονός που σημαίνει ότι το παράθυρο μετατοπίζεται κατά:

$$\frac{512}{32000} = 0.016 \text{ sec}$$

ή 16 ms σε κάθε βήμα. Ως αποτέλεσμα παράγονται περίπου:

$$\frac{32000}{512} = 62.5$$

χρονικά πλαίσια (*frames*) ανά δευτερόλεπτο.

Στη συνέχεια το φάσμα συχνοτήτων συμπίεστηκε σε 128 ζώνες Mel (*Mel bins*). Η κλίμακα Mel αποτελεί μία μη γραμμική αναπαράσταση των συχνοτήτων η οποία προσεγγίζει τον τρόπο με τον οποίο το ανθρώπινο ακουστικό σύστημα αντιλαμβάνεται τις τονικές διαφορές. Με τον τρόπο αυτό μειώνεται η διάσταση των δεδομένων, ενώ παράλληλα διατηρούνται οι σημαντικότερες ακουστικές πληροφορίες του σήματος.

Η τελική αναπαράσταση κάθε παραθύρου έχει διαστάσεις 128×313 , όπου ο κατακόρυφος άξονας αντιστοιχεί στις Mel συχνότητες και ο οριζόντιος στον χρόνο.

Για λόγους υπολογιστικής αποδοτικότητας και περιορισμού του χρόνου εκπαίδευσης, στο τελικό μοντέλο χρησιμοποιήθηκαν μόνο τα πρώτα 15 δευτερόλεπτα κάθε ηχογράφησης. Η επιλογή αυτή βασίστηκε σε προκαταρκτική ανάλυση των δεδομένων, η οποία έδειξε ότι στις περισσότερες περιπτώσεις τα χαρακτηριστικά φωνητικά μοτίβα των πτηνών εμφανίζονται ήδη στα πρώτα δευτερόλεπτα της καταγραφής.

Τα πρώτα 15 δευτερόλεπτα διαχωρίστηκαν σε τρία διαδοχικά μη επικαλυπτόμενα χρονικά παράθυρα διάρκειας 5 δευτερολέπτων. Για κάθε παράθυρο δημιουργήθηκε ξεχωριστό Mel Spectrogram, με αποτέλεσμα κάθε ηχογράφηση να αναπαρίσταται τελικά από τενσορ διαστάσεων:

$$[3, 1, 128, 313]$$

όπου η πρώτη διάσταση αντιστοιχεί στα τρία χρονικά παράθυρα, η δεύτερη στο μοναδικό κανάλι εισόδου και οι δύο τελευταίες στις διαστάσεις του Mel Spectrogram.

5 Ανάλυση Συνόλου Δεδομένων

Από δειγματοληπτικό έλεγχο 500 ηχογραφήσεων προέκυψε ότι η διάρκεια των καταγραφών παρουσιάζει σημαντική μεταβλητότητα. Συγκεκριμένα, η μικρότερη ηχογράφηση είχε διάρκεια 0.10


δευτερόλεπτα, η μέση διάρκεια ήταν 38.84 δευτερόλεπτα, ενώ η μεγαλύτερη ξεπερνούσε τα 1100 δευτερόλεπτα.

Πίνακας 1: Στατιστικά διάρκειας ηχογραφήσεων

Μέτρο	Τιμή (sec)
Ελάχιστη διάρκεια	0.10
Μέση διάρκεια	38.84
Μέγιστη διάρκεια	1147.95

Η μεγάλη διακύμανση στη διάρκεια των ηχογραφήσεων ανέδειξε την ανάγκη χρήσης κοινής μορφής εισόδου για όλα τα δείγματα. Αρχικά εξετάστηκε η μετατροπή κάθε ηχογράφησης σε διάρκεια 60 δευτερολέπτων μέσω περικοπής (truncation) ή συμπλήρωσης με μηδενικά (zero-padding). Ωστόσο, λόγω της σχετικά χαμηλής μέσης διάρκειας των καταγραφών, η προσέγγιση αυτή οδηγούσε στη δημιουργία μεγάλων περιοχών χωρίς χρήσιμη πληροφορία.

Το Σχήμα 2 παρουσιάζει ένα χαρακτηριστικό παράδειγμα ηχογράφησης μετά τον διαχωρισμό της σε 12 παράθυρα διάρκειας 5 δευτερολέπτων.



Σχήμα 2: Παράδειγμα ηχογράφησης χωρισμένης σε 12 χρονικά παράθυρα.

Παρατηρείται ότι το μεγαλύτερο μέρος του βιοακουστικού σήματος συγκεντρώνεται στα πρώτα χρονικά παράθυρα, ενώ τα τελευταία περιέχουν κυρίως σιωπή ή μηδενική συμπλήρωση. Η παρατήρηση αυτή υποδηλώνει ότι η χρήση ολόκληρου του 60-δευτερολέπτου δεν προσφέρει πάντοτε επιπλέον πληροφορία στο μοντέλο, ενώ αυξάνει σημαντικά τις απαιτήσεις σε μνήμη και χρόνο εκπαίδευσης.

Για τον λόγο αυτό, στο τελικό σύνολο πειραμάτων επιλέχθηκε η χρήση μόνο των πρώτων 15 δευτερολέπτων κάθε ηχογράφησης. Τα 15 δευτερόλεπτα χωρίστηκαν σε τρία διαδοχικά μη επικαλυπτόμενα παράθυρα διάρκειας 5 δευτερολέπτων, μειώνοντας σημαντικά τον υπολογιστικό φόρτο και περιορίζοντας την παρουσία περιοχών χωρίς χρήσιμη ακουστική πληροφορία.

Η επιλογή αυτή επέτρεψε την αποδοτικότερη εκπαίδευση των μοντέλων, διατηρώντας παράλληλα τα σημαντικότερα φωνητικά μοτίβα που απαιτούνται για την αναγνώριση των ειδών.

6 Μέθοδος

6.1 Αρχιτεκτονική CNN με Max Pooling

Η βασική αρχιτεκτονική που εξετάστηκε βασίζεται σε Convolutional Neural Networks (CNNs) για την εξαγωγή χαρακτηριστικών από τα Mel Spectrograms. Κάθε ηχογράφηση αναπαρίσταται από τρία διαδοχικά χρονικά παράθυρα διάρκειας 5 δευτερολέπτων, τα οποία αντιστοιχούν στα πρώτα 15 δευτερόλεπτα της καταγραφής. Επομένως, κάθε δείγμα εισόδου έχει τη μορφή tensor διαστάσεων [3, 1, 128, 313].


Κάθε χρονικό παράθυρο εισέρχεται ανεξάρτητα σε έναν κοινό CNN Encoder. Ο encoder αποτελείται από τέσσερα διαδοχικά συνελικτικά επίπεδα με 32, 64, 128 και 256 κανάλια αντίστοιχα. Στα τρία πρώτα επίπεδα εφαρμόζονται διαδοχικά Convolution, Batch Normalization, συνάρτηση ενεργοποίησης ReLU και Max Pooling. Στο τέταρτο επίπεδο εφαρμόζονται Convolution, Batch Normalization και ReLU, χωρίς επιπλέον Max Pooling.

Στο τέλος του encoder χρησιμοποιείται Adaptive Average Pooling διαστάσεων 4×4 , ώστε η έξοδος να αποκτήσει σταθερή χωρική διάσταση ανεξάρτητα από το ακριβές μέγεθος της εισόδου. Στη συνέχεια εφαρμόζονται Flatten, Dropout με πιθανότητα 0.4 και πλήρως συνδεδεμένο επίπεδο, το οποίο παράγει διάνυσμα χαρακτηριστικών διαστάσεων 512 για κάθε χρονικό παράθυρο.

Τα τρία διανύσματα χαρακτηριστικών που αντιστοιχούν στα τρία παράθυρα της ίδιας ηχογράφησης συνενώνονται σε μία ακολουθία διαστάσεων [3, 512]. Η τελική αναπαράσταση της ηχογράφησης προκύπτει με Max Pooling κατά μήκος της χρονικής διάστασης, δηλαδή επιλέγεται η μέγιστη ενεργοποίηση κάθε χαρακτηριστικού ανάμεσα στα τρία παράθυρα.

Η χρήση Max Pooling επιλέχθηκε επειδή τα βιοακουστικά σήματα δεν εμφανίζονται απαραίτητα συνεχώς σε όλη τη διάρκεια της ηχογράφησης. Με αυτόν τον τρόπο το μοντέλο μπορεί να διατηρήσει τα ισχυρότερα ακουστικά μοτίβα που εμφανίζονται σε οποιοδήποτε από τα τρία παράθυρα, χωρίς αυτά να αποδυναμώνονται από λιγότερο πληροφοριακά τμήματα.

Η τελική αναπαράσταση οδηγείται σε πλήρως συνδεδεμένο επίπεδο ταξινόμησης, μετά από Dropout 0.4, το οποίο παράγει τις τελικές προβλέψεις για τις 30 κατηγορίες ειδών.



Σχήμα 3: Αρχιτεκτονική CNN με Max Pooling.

6.2 Αρχιτεκτονική υβριδικού μοντέλου CNN-BiLSTM

Η δεύτερη αρχιτεκτονική που εξετάστηκε βασίζεται σε συνδυασμό Convolutional Neural Networks (CNNs) και Bidirectional Long Short-Term Memory (BiLSTM) δικτύων, με στόχο την αξιοποίηση τόσο των τοπικών ακουστικών χαρακτηριστικών όσο και της χρονικής αλληλουχίας των τμημάτων κάθε ηχογράφησης. Όπως και στην προηγούμενη προσέγγιση, κάθε ηχογράφηση αναπαρίσταται από τρία διαδοχικά χρονικά παράθυρα διάρκειας 5 δευτερολέπτων, τα οποία αντιστοιχούν στα πρώτα 15 δευτερόλεπτα της καταγραφής. Επομένως, κάθε δείγμα εισόδου έχει τη μορφή tensor διαστάσεων [3, 1, 128, 313].


Κάθε χρονικό παράθυρο εισέρχεται ανεξάρτητα σε έναν κοινό CNN Encoder. Ο encoder αποτελείται από τέσσερα διαδοχικά συνελικτικά επίπεδα με 32, 64, 128 και 256 κανάλια αντίστοιχα. Στα τρία πρώτα επίπεδα εφαρμόζονται διαδοχικά Convolution, Batch Normalization, συνάρτηση ενεργοποίησης ReLU και Max Pooling. Στο τέταρτο επίπεδο εφαρμόζονται Convolution, Batch Normalization και ReLU, χωρίς επιπλέον Max Pooling.

Στο τέλος του encoder χρησιμοποιείται Adaptive Average Pooling, το οποίο συμπυκνώνει τις χωρικές πληροφορίες σε ένα διάνυσμα χαρακτηριστικών σταθερού μεγέθους. Στη συνέχεια εφαρμόζεται Flatten, παράγοντας για κάθε χρονικό παράθυρο μία συμπαγή αναπαράσταση χαρακτηριστικών διαστάσεων 256.

Τα τρία διανύσματα χαρακτηριστικών που αντιστοιχούν στα τρία παράθυρα της ίδιας ηχογράφησης συνενώνονται σε μία χρονική ακολουθία διαστάσεων [3, 256]. Η ακολουθία αυτή εισέρχεται σε ένα δίκτυο Bidirectional Long Short-Term Memory (BiLSTM), το οποίο επεξεργάζεται ταυτόχρονα τη χρονική πληροφορία τόσο προς την εμπρόσθια όσο και προς την αντίθετη κατεύθυνση. Με τον τρόπο αυτό το μοντέλο μπορεί να αξιοποιήσει σχέσεις μεταξύ των διαφορετικών τμημάτων της ηχογράφησης και να καταγράψει τη χρονική εξέλιξη των ακουστικών γεγονότων.

Το BiLSTM χρησιμοποιεί κρυφή διάσταση 256 μονάδων ανά κατεύθυνση, παράγοντας έξοδο διαστάσεων 512 για κάθε χρονικό βήμα. Ως τελική αναπαράσταση της ηχογράφησης χρησιμοποιείται η έξοδος του τελευταίου χρονικού βήματος του BiLSTM, η οποία συνοψίζει την πληροφορία που έχει συγκεντρωθεί από ολόκληρη την ακολουθία των τριών παραθύρων.

Η τελική αναπαράσταση οδηγείται σε επίπεδο Dropout με πιθανότητα 0.3 και στη συνέχεια σε πλήρως συνδεδεμένο επίπεδο ταξινόμησης, το οποίο παράγει τις τελικές προβλέψεις για τις 30 κατηγορίες ειδών. Σε αντίθεση με την προσέγγιση CNN-Max, η συγκεκριμένη αρχιτεκτονική δεν επιλέγει απλώς τα ισχυρότερα χαρακτηριστικά ανάμεσα στα παράθυρα, αλλά επιχειρεί να μοντελοποιήσει τη χρονική ακολουθία των ακουστικών μοτίβων μέσα στην ηχογράφηση.



Σχήμα 4: Αρχιτεκτονική υβριδικού μοντέλου CNN-BiLSTM.

6.3 Προσέγγιση Αναφοράς με Perch Embeddings

Εκτός από το μοντέλο CNN που εκπαιδεύτηκε από την αρχή, χρησιμοποιήθηκε ως προσέγγιση αναφοράς το προεκπαιδευμένο μοντέλο Perch Bird Vocalization Classifier της Google. Το Perch αποτελεί μοντέλο εξαγωγής βιοακουστικών αναπαραστάσεων, εκπαιδευμένο σε μεγάλο όγκο ηχητικών δεδομένων πτηνών.

Για κάθε ηχογράφηση εξήχθησαν embeddings μέσω του προεκπαιδευμένου μοντέλου, χωρίς να γίνει περαιτέρω εκπαίδευση των βαρών του. Τα παραγόμενα embeddings χρησιμοποιήθηκαν στη συνέχεια ως είσοδος σε ταξινομητή Logistic Regression, ο οποίος εκπαιδεύτηκε στο ίδιο σύνολο δεδομένων των 30 ειδών.

Η προσέγγιση αυτή χρησιμοποιήθηκε ως ισχυρό baseline, ώστε να συγκριθεί η απόδοση ενός μοντέλου που εκπαιδεύεται από την αρχή με την απόδοση ενός προεκπαιδευμένου βιοακουστικού μοντέλου που αξιοποιεί γνώση από μεγαλύτερης κλίμακας δεδομένα.

6.4 Πείραμα Ανθεκτικότητας σε Θόρυβο

Για την αξιολόγηση της ανθεκτικότητας (robustness) των μοντέλων σε ρεαλιστικές συνθήκες καταγραφής, δημιουργήθηκε επιπλέον πειραματικό σύνολο με προσθήκη φυσικού θορύβου στις ηχογραφίες ελέγχου.

Ο θόρυβος προήλθε από αρχεία soundscapes του συνόλου δεδομένων BirdCLEF 2026, ώστε να προσομοιωθούν φυσικά περιβάλλοντα όπως αέρας, έντομα, νερό, άλλες φωνές ζώων και γενικός περιβαλλοντικός θόρυβος. Με αυτόν τον τρόπο η αξιολόγηση δεν περιορίστηκε σε τεχνητό λευκό θόρυβο, αλλά βασίστηκε σε πιο ρεαλιστικές ακουστικές παρεμβολές.

Δημιουργήθηκαν δύο εκδοχές του συνόλου ελέγχου, καθεμία με διαφορετικό επίπεδο έντασης θορύβου. Τα επίπεδα θορύβου αντιστοιχούν σε μεσαία και υψηλή παρεμβολή, με στόχο να εξεταστεί πώς μεταβάλλεται η απόδοση των μοντέλων όσο δυσκολεύουν οι συνθήκες ακρόασης. Για κάθε επίπεδο θορύβου υπολογίστηκαν οι ίδιες μετρικές αξιολόγησης με το αρχικό καθαρό σύνολο ελέγχου, επιτρέποντας την άμεση σύγκριση της απόδοσης μεταξύ καθαρών και θορυβωδών ηχογραφήσεων.

6.5 Διαδικασία Εκπαίδευσης και Αξιολόγησης

Το CNN μοντέλο εκπαιδεύτηκε στο πρόβλημα πολυταξικής ταξινόμησης 30 κατηγοριών. Για τη συνάρτηση κόστους χρησιμοποιήθηκε η Cross-Entropy Loss, η οποία είναι κατάλληλη για περιπτώσεις που κάθε δείγμα ανήκει σε μία μόνο κατηγορία.

Για τη βελτιστοποίηση των παραμέτρων χρησιμοποιήθηκε ο αλγόριθμος AdamW με ρυθμό μάθησης 3×10^{-4} και weight decay 10^{-4} . Η εκπαίδευση πραγματοποιήθηκε για μέγιστο αριθμό 60 εποχών, με μηχανισμό early stopping όταν η απώλεια στο σύνολο επικύρωσης δεν βελτιωνόταν για 7 συνεχόμενες εποχές.

Κατά τη διάρκεια της εκπαίδευσης αποθηκευόταν το μοντέλο με τη χαμηλότερη τιμή validation loss. Η αξιολόγηση των μοντέλων πραγματοποιήθηκε χρησιμοποιώντας τις μετρικές Accuracy, Macro F1 Score, Weighted F1 Score, Macro AUC και Top-k Accuracy.

7 Αποτελέσματα

Πίνακας 2: Αποτελέσματα των μοντέλων στο σύνολο ελέγχου

Μοντέλο	Accuracy	Macro F1	Weighted F1	Top-3	Top-5
CNN	0.789	0.789	0.789	0.889	0.926
CNN-BiLSTM	0.661	0.659	0.659	0.824	0.876
Perch + Logistic Regression	0.923	0.923	0.923	0.966	0.977

Πίνακας 3: Αποτελέσματα αξιολόγησης σε θορυβώδη δεδομένα

Μοντέλο	Θόρυβος	Accuracy	Macro F1	Weighted F1	Top-3	Top-5
CNN	Medium	0.540	0.520	0.546	0.750	0.810
CNN	Heavy	0.460	0.439	0.458	0.650	0.760
Perch + LR	Medium	0.760	0.713	0.746	0.850	0.900
Perch + LR	Heavy	0.730	0.695	0.716	0.800	0.860

8 Συμπεράσματα

Η παρούσα εργασία διερευνά την αποτελεσματικότητα διαφορετικών προσεγγίσεων στην αυτόματη αναγνώριση ειδών πτηνών από ηχητικές καταγραφές του BirdCLEF 2026. Τα αποτελέσματα έδειξαν ότι η χρήση προεκπαιδευμένων αναπαραστάσεων μέσω του μοντέλου Perch οδηγεί σε υψηλότερες επιδόσεις τόσο σε συνθήκες καθαρών δεδομένων όσο και σε συνθήκες παρουσίας θορύβου. Το εύρημα αυτό υποδηλώνει ότι η εκπαίδευση σε πολύ μεγάλης κλίμακας βιοακουστικά σύνολα δεδομένων επιτρέπει την εκμάθηση πιο γενικεύσιμων χαρακτηριστικών σε σχέση με την εκπαίδευση ενός μοντέλου αποκλειστικά στα διαθέσιμα δεδομένα.

Ένα από τα βασικότερα συμπεράσματα αφορά τον όγκο των διαθέσιμων δεδομένων. Παρότι εφαρμόστηκε εξισορρόπηση των κατηγοριών και χρησιμοποιήθηκαν οι 30 συχνότερες κλάσεις του συνόλου δεδομένων, η περαιτέρω αύξηση του αριθμού καταγραφών ανά είδος αναμένεται να βελτιώσει σημαντικά την ικανότητα γενίκευσης των μοντέλων και ιδιαίτερα των αρχιτεκτονικών που εκπαιδεύονται από την αρχή.

Κατά τη διάρκεια των πειραμάτων διαπιστώθηκε επίσης ότι οι διαθέσιμοι υπολογιστικοί πόροι αποτελούν καθοριστικό παράγοντα στον σχεδιασμό των μοντέλων. Οι περιορισμοί μνήμης και χρόνου εκπαίδευσης περιόρισαν το βάθος των συνελικτικών αρχιτεκτονικών που μπορούσαν να εξεταστούν, οδηγώντας στην επιλογή σχετικά ρηχών δικτύων τεσσάρων συνελικτικών επιπέδων. Είναι πιθανό, βαθύτερες αρχιτεκτονικές ή μεγαλύτερα μοντέλα να μπορούσαν να επιτύχουν υψηλότερες επιδόσεις εφόσον ήταν διαθέσιμοι περισσότεροι υπολογιστικοί πόροι.

Η σύγκριση μεταξύ CNN και CNN-BiLSTM έδειξε ότι η προσθήκη μηχανισμών χρονικής μοντελοποίησης δεν συνεπάγεται απαραίτητα σημαντική βελτίωση της απόδοσης. Αντίθετα, το CNN-BiLSTM αύξησε αισθητά το υπολογιστικό κόστος εκπαίδευσης χωρίς να συνεισφέρει αντίστοιχα στην αύξηση της ταξινομητικής ικανότητας. Το εύρημα αυτό υποδηλώνει ότι για σχετικά σύντομες ηχογραφήσεις (15 sec) η πληροφορία που παρέχεται από τα συνελικτικά χαρακτηριστικά ενδέχεται να επαρκεί.

Ιδιαίτερο ενδιαφέρον παρουσίασε η επίδραση της μεθόδου συνάντρωσης των χρονικών παραθύρων. Τα πειράματα έδειξαν ότι η χρήση Max Pooling οδήγησε σε καλύτερα αποτελέσματα σε σχέση με το Average Pooling, ιδιαίτερα στα αρχικά πειράματα όπου χρησιμοποιήθηκαν μεγαλύτερες ηχογραφήσεις διάρκειας 60 δευτερολέπτων. Το αποτέλεσμα αυτό συμφωνεί με τη φύση των βιοακουστικών

δεδομένων, όπου σημαντικά ακουστικά γεγονότα μπορεί να εμφανίζονται μόνο σε μικρό τμήμα της καταγραφής.

Τέλος, τα πειράματα ανθεκτικότητας σε θόρυβο ανέδειξαν τη σημαντική επίδραση του περιβαλλοντικού θορύβου στην απόδοση των μοντέλων. Η παρατηρούμενη υποβάθμιση υποδεικνύει ότι η ενσωμάτωση θορυβωδών παραδειγμάτων κατά τη διαδικασία εκπαίδευσης ή η χρήση τεχνικών ενίσχυσης δεδομένων (data augmentation) με φυσικούς περιβαλλοντικούς ήχους θα μπορούσε να βελτιώσει περαιτέρω την ανθεκτικότητα των μοντέλων σε πραγματικές συνθήκες ηχογράφησης.

Αναφορές

- [1] Stefan Kahl, Tom Denton, Larissa Sugai, Liliana Piatti, Ryan Holbrook, Holger Klinck, and Ashley Oldacre. Birdclef+ 2026. <https://kaggle.com/competitions/birdclef-2026>, 2026. Kaggle.
- [2] Dan Stowell. Computational bioacoustics with deep learning: a review and roadmap. *CoRR*, abs/2112.06725, 2021.
- [3] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [4] S Hochreiter. Long short-term memory. *Neural Computation MIT-Press*, 1997.
- [5] Mike Schuster and Kuldeep K Paliwal. Bidirectional recurrent neural networks. *IEEE transactions on Signal Processing*, 45(11):2673–2681, 1997.

A' Κώδικας

Ο πλήρης πηγαίος κώδικας της εργασίας διατίθεται δημόσια μέσω ψηφιακού αποθετηρίου στον ακόλουθο GitHub σύνδεσμο:

<https://github.com/GElpida/mscai-dl-project.git>